Embate entre modelos da família GARCH: Previsão da volatilidade do índice S&P 500.

Francisco Zipman Kevin Pereira Lima Lucca Costa

Novembro, 2024

Resumo

Nesse artigo, focamos em realizar uma comparação entre um conjunto de modelos GARCH (t-GARCH, EGARCH, GJR-GARCH e GARCH padrão) de tal a forma a buscar identificar o melhor modelo com foco na predição do S&P 500, para isso usamos ferramentas como MAE, MSE, RMSE log-verossimilhança e o teste Diebold-Mariano. Encontramos que a diferença de predição entre os modelos t-GARCH e GJR-GARCH não é estatisticamente significantes, mesmo que o modelo t-GARCH apresente melhores estatísticas relativas ao MSE, RMSE e log-verossimilhança não somos capazes de afirmar que a diferença de predição entre esses modelos é estatisticamente relevantes, todavia fomos capazes de trazer a tona no debate academcio que existe importancia de modelar a distribuição dos erros.

Palavras-chaves: GARCH, Predição, S&P 500 e Volatilidade

1 Introdução

A modelagem de previsão de volatilidade vem se tornando um quesito central para o mundo financeiro e acadêmico hoje em dia, no final das contas volatilidade é essencial não só para outros tipos de modelos, como o de Black-Scholes por (BLACK; SCHOLES, 1973) sobre a qual volatilidade se torna um parâmetro na precificação de uma opção, mas também se torna de extrema importância a volatilidade em estratégias de investimentos, como por exemplo volatility carry que como estratégia de trading busca gerar lucro partindo da diferença entre implied volatility e realized volatility de um ativo. Em geral, volatilidade é um quesito importante para tomada de decisões em finanças, dessa forma se torna essencial tentar prever essa para períodos futuros.

Ao pensar em modelagem e predição de tal volatilidade o quesito mais simples de abordagem seria o modelo ARCH(p) por (ENGLE, 1982), tal modelo busca descrever a volatilidade de amanhã com base no resíduo passado de um outro modelo implícito y_t.

Pensando em um quesito de generalização e maior aperfeiçoamento do modelo ARCH(p) temos o modelo GARCH(p,q) de (BOLLERSLEV, 1986) que descreve a volatilidade de amanhã não só com base nos resíduos passados de um modelo y_t implícito mas também com base na volatilidade passada. Ambos modelos, já são capazes de representar um indicador importante de volatilidade no mercado que é volatility clustering, ou seja a volatilidade em sí não é homocedástica e acaba por depender do tempo, logo acaba flutuando com o tempo, ainda assim esses modelos acabam por ser simplificações e se limitam em não representar fatores diversos observados no mercado, sendo um exemplo claro choque de retornos negativos terem efeitos maiores sobre a volatilidade que choques de retornos positivos de mesma magnitude (assimetria), além de diversos outros fatores como discutidos por (STARICA, 2003) e (AWARTANI; CORRADI, 2005), que serão melhor abordados no Capítulo 2.

Dessa forma, o nosso estudo busca fazer uma comparação entre a capacidade preditiva de diversos modelos de volatilidade, para isso usaremos como abordagem comparativa base o modelo GARCH(1,1) que não só será a base de comparação, mas também será a base de extrapolação que os outros modelos de comparação devem partir, ao considerar diversos fatores importantes na modelagem de ativos, mercado e volatilidade em sí. Os principais modelos de extrapolação para o Garch que foram usados são, tanto o GJR-Garch e E-Garch que buscam modelar assimetria, assim como o Garch-t que foca em modelar a distribuição do erro mais precisamente. Também teremos como foco considerativo o S&P 500 no intervalo de 2017 a 2024, um dos índices mais importantes para o mercado financeiro, sendo o conjunto das 500 maiores empresas de capital aberto listado nas bolsas de valores dos EUA. Por último, relativo a série da volatilidade para o S&P 500, uma variável não observável diretamente, foi decidido usar retornos quadrados da série histórica do S&P 500, ou seja volatilidade realizada, como proxy para volatilidade geral.

2 Revisão bibliográfica

Para um melhor entendimento sobre modelos de previsão de volatilidade, principalmente voltado modelos Garch, passaremos por uma revisão central da literatura presente até o momento, com o intuito de obter um maior conhecimento sobre a aplicabilidade desse modelo, em especial para o S&P 500, permitindo também maior informação das limitações sobre o presente modelo, além disso consideramos a aplicabilidade desse modelo básico em um quesito comparativo preditivo a outros modelos de volatilidade para extrapolações do Garch. Chegaremos a conclusão que não existe um consentimento acadêmico em determinar qual o melhor modelo de volatilidade pensando em um quesito preditivo.

Um importante estudo analítico e critico do desempenho da qualidade previsão do GARCH foi (STARICA, 2003), assim como esse trabalho o texto foca em predição para o S&P 500. Tal texto conclui que o modelo GARCH não é estatisticamente diferente em predição a outros modelos não estacionários simples. (STARICA, 2003) consegue ressaltar e indicar as inúmeras limitações desse modelo devido a incapacidade de modelar assimetria, threshold e distribuição de erros mais sofisticadas. Essas limitações, revelam fortemente os problemas na capacidade preditiva do modelo GARCH, indicando a importância de propor melhorias a esse.

Partindo do entendimento das limitações do modelo GARCH, (AWARTANI; CORRADI, 2005) e (LIU; HUNG, 2010) buscam comparar diferentes extrapolações do GARCH, já considerativo de diversos ajustes, focando na capacidade preditiva desses

modelos. Para isso os seguintes artigos olhando para o S&P 500 e S&P 100, focam em comparar a previsão de diversos modelos considerativos de extrapolações voltados para: modelagem de assimetria (EGARCH, GJR-GARCH e outros), modelagem da distribuição do erro (t-GARCH, GARCH-HT e outros), além de alguns outros quesitos como threshold. (AWARTANI; CORRADI, 2005) e (LIU; HUNG, 2010) concluem, na importância de modelagem e considerações de assimetria, indicando os modelos AGARCH e GJR-GARCH como dominante em previsão, encontrando também que quando não considerando assimetria o melhor modelo se encontra no GARCH(1,1).

Em contrapartida, o artigo de (SRINIVASAN, 2011) passa pelo mesmo experimento apenas variando o intervalo de tempo, mas acaba por concluir a importância de modelar simetria em diferença de assimetria, demonstrando então um universo de debate acadêmico sem consentimento de melhor modelo para caráter de previsão. Tal situação é ainda mais evidência pelo artigo de (MARTENS; DIJK; POOTER, 2004), tal artigo propõe como uma possível alternativa por um modelo considerativo de não linearidade no formato de um AFIRMA, acabando por concluir uma melhor capacidade preditiva e importância de modelagem de um quesito de não linearidade. Dessa forma tanto o artigo de (MARTENS; DIJK; POOTER, 2004) quanto o de (SRINIVASAN, 2011), indicam a falta de um consentimento no universo acadêmico voltada para o melhor modelo preditivo de volatilidade para o S&P 500, divergindo em qual quesito de modelagem para melhor previsão se torna mais importante.

Dessa forma, nosso estudo segue a linha já pré-estabelecida de um universo acadêmico de discordância na seleção de modelos com base preditiva de volatilidade voltado para o S&P 500, com objetivo de progredir esse debate, para isso focamos assim como diversos outros estudos em comparar o caráter preditivo entre modelos com base no GARCH, mantendo o objetivo de achar um melhor modelo preditivo geral entre as diversas extrapolações de GARCH.

3 Dados

Então, antes de estudarmos como o modelo GARCH e seus derivados modelam e preveêm o comportamento da volatidade do S&P 500, devemos realizar a análise descritiva da nossa série histórica. Para tal, medimos as seguintes estatíticas descritivas, de modo a reconhecer as características dos log-retornos[1] do índice, na Tabela 1:

Tabela 1 – Estatísticas Descritivas:

Métrica	Valor
Média	0.0004581
Variância	0.0001416
Assimetria	-0.8552
Kurtosis	16.1056

Fonte: Próprio Autor.

Além disso, apresentamos os gráficos da série histórica do S&P 500 e de suas funções de autocorrelação total e parcial nas Figuras 1 e 2:

[1] $\text{Retorno}_{Log} = ln(\frac{p_t}{p_{t-1}})$

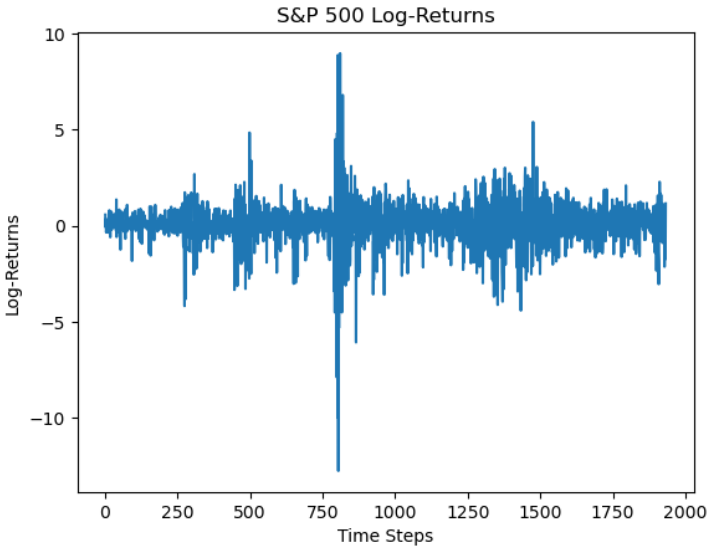

Figura 1 – Série histórica dos Retornos Logarítimicos do S&P 500, de 2017 a 2024.

Fonte: Próprio Autor.

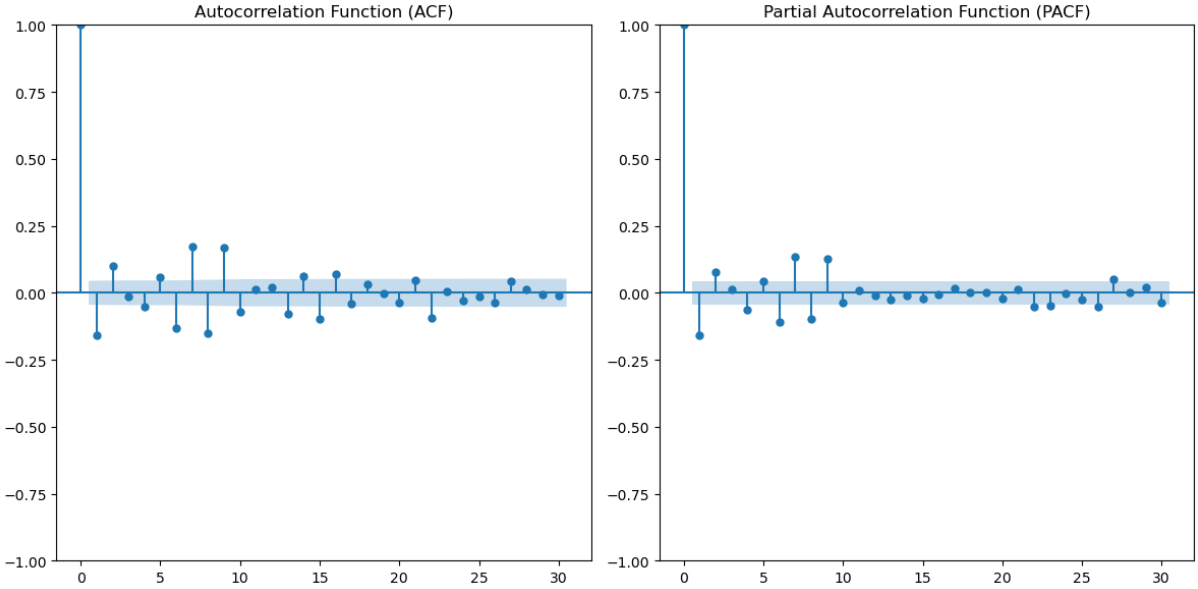

Figura 2 – Funções de Autocorrelação Total e Parcial da Série histórica dos Retornos logarítimicos do S&P 500, de 2017 a 2024.

Fonte: Próprio Autor.

Tendo descrito a nossa base de dados e a correlação entre os *lags* da nossa série histórica, devemos identificar se há normalidade da distribuição dos nossos retornos logarítimicos, e se há presença de heterocedasticidade, o que é suficiente para argumentarmos a necessidade de modelar a volatilidade do S&P 500 a fim de prevê-la. Portanto, realizamos dois testes estatísticos para responder essas questões respectivamente:

- **Teste de Kolmogorov-Smirnov (KS)**: Procura avaliar se alguma distribuição se aproxima o suficiente de uma referência, nesse caso a normal. Sua estatística se baseia na distância da distribuição real F(x) e a de referência (S(x)), de modo que

temos as seguintes hipóteses:

$$H_0 : F(x) = S(x)$$

$$H_1 : F(x) \neq S(x)$$

- **Teste de White**: É um teste que identifica se a variância do modelo em questão é heterocedástica[2] ou não. Seu método é feito com a estimação de um modelo populacional usado para modelar a série dos residuos quadráticos, $u_i^2 = \delta_1 x_{1,i} + ...\delta_h x_{h,i} + ...\delta_k x_{k,i} x_{j,i} + ...\delta_p x_{p,i}^p, \forall\ h, k \in (1, ..., p), \forall\ i \in (1, ..., n)$, de modo que suas hipóteses são:

$$H_0 : \delta_1 = ... = \delta_h = 0 \text{ (Homecedasticidade)}$$

$$H_1 : \delta_1, ..., \delta_h \neq 0 \text{ (Heterocedasticidade)}$$

Tabela 2 – Testes Estatísticos:

Teste	Valor	P-valor
Teste KS	0.4813	0.0
Teste de White	761.188	3.636e-203

Fonte: Próprio Autor.

Assim, rejeitamos a H_0 em ambos os testes feitos para um nível de significância de 5%. Portanto, podemos dizer que a série de retornos logarítimicos nem é normal e nem é homocedástica, e sim heterocedástica. Isso nos dá suficiência para podermos modelar a volatilidade do S&P 500. Nas figuras 3 e 4 seguem os gráficos tanto da volatilidade do índice quanto das suas funções de autocorrelação total e parcial:

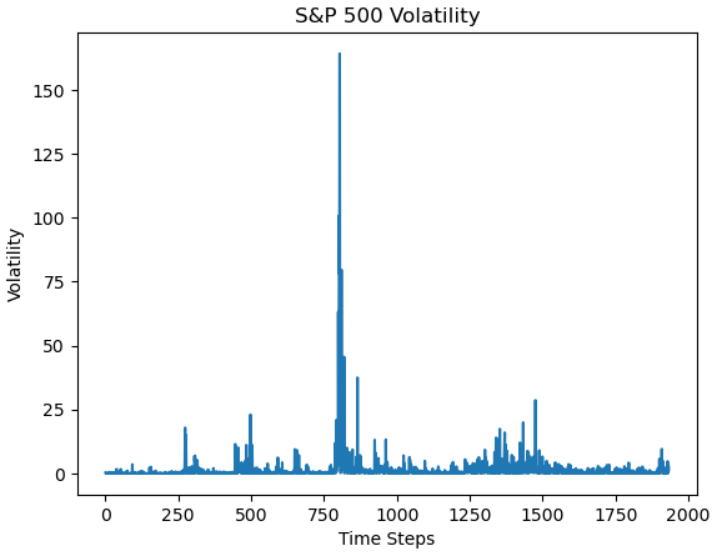

Figura 3 – Série histórica da Volatilidade do S&P 500, de 2017 a 2024.

Fonte: Próprio Autor.

[2] Variância dos erros é dependente para cada observação i, ou seja: $\sigma_u = \sigma_{u,i}$

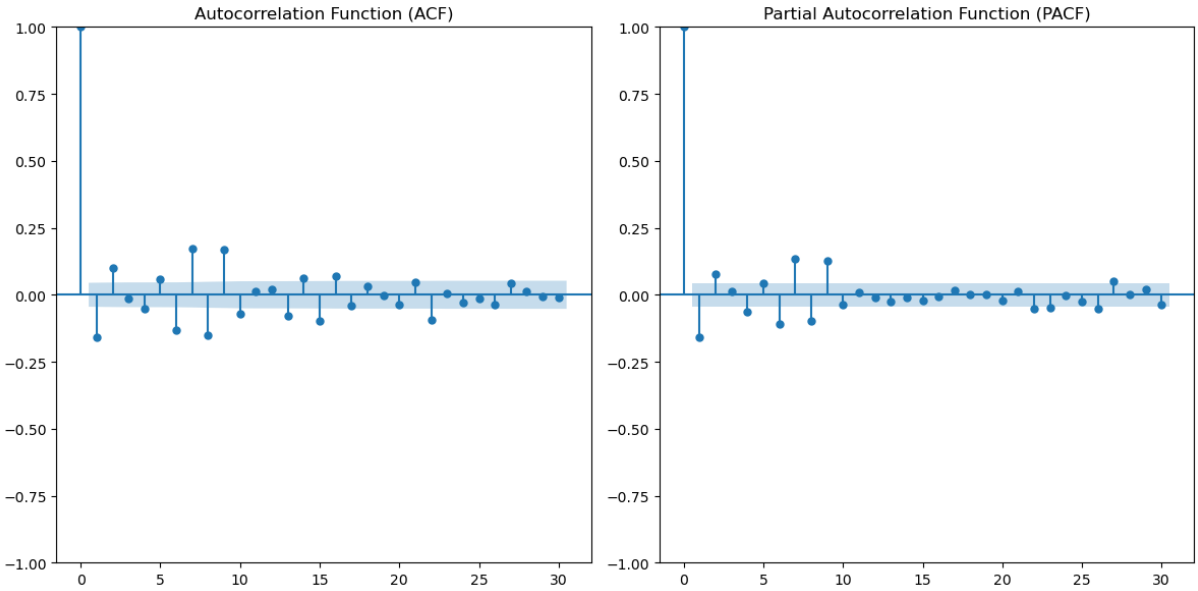

Figura 4 – Funções de Autocorrelação Total e Parcial da Série histórica da Volatilidade do S&P 500, de 2017 a 2024.

Fonte: Próprio Autor.

4 Metodologia

Uma vez feita nossa análise exploratória e adptação da base de dados do S&P 500 para nossos fins, é necessário explicitar a metodologia do nosso projeto. Para que seja possivel modelarmos a volatilidade dos retornos do índice, como dito anteriormente na seção 1, o modelo GARCH(p,q) será necessário. Ao realizarmos a otimização das ordens do modelo geral a partir do menor Critério de Informação Akaike (AIC)[3], escolhemos o GARCH(1,1), dado pela seguinte regressão[4]:

$$\sigma_t^2 = \omega + \alpha\epsilon_{t-1}^2 + \beta\sigma_{t-1}^2$$

Além disso, o objetivo de nosso artigo é justamente progredir no debate de qual modelagem de volatilidade do S&P 500 é capaz de um maior poder preditivo geral. Assim, utilizamos 3 dos modelos apresentados na seção 2, juntamente com o GARCH(1,1) para promover o embate econométrico proposto incialmente: EGARCH(p,q)[5], GJR-GARCH(p,q)[6], que incluem assimetria na modelagem, e t-GARCH(p,q)[7], que muda a distribuição dos erros para uma t-student. Todos eles serão padronizados para as ordens (1,1), de modo a

[3] Critério que pealiza a complexidade do modelo *(numero de parâmetros)* para evitar o sobreajuste. O critério AIC é dado por $AIC = -2logL \ + 2(k)$, Onde L é a função de verossimilhança do modelo estimado e k e o número de parâmetros no modelo *(incluindo p, q e a variância)*.

[4] $\epsilon_t|N(0,1)$

[5] $log\ \sigma_t^2 = \omega + \sum_{k=1}^{q} \beta_k g(Z_{t-k}) + \sum_{k=1}^{p} \alpha_k\ log\ \sigma_{t-k}^2$, tal que $g(Z_t) = \theta Z_t + \lambda(|Z_t| - E(|Z_t|))$, com cada letra grega sendo coeficientes e Z_t sendo uma variável aleatória vindo de uma distribuição de erro normal ou outra generalizada.

[6] $\sigma_t^2 = K + \delta\sigma_{t-1}^2 + \alpha\epsilon_{t-1}^2 + \phi\epsilon_{t-1}^2)I_{t-1}$, sendo que $I_{t-1} = 0$, se $\epsilon_{t-1} \geq 0$ e $I_{t-1} = 1$ se $\epsilon_{t-1} < 0$, sendo que modelamos o erro como $\epsilon_t = \sigma_t z_t$, com z_t sendo IID.

[7] Parecido com o modelo GJR-GARCH, porém trata do desvio-padrão condicional ao invés da variância condicional σ_t^2: $\sigma_t = K + \delta\sigma_{t-1} + \alpha_1^+\epsilon_{t-1}^+ + \alpha_{t-1}^-\epsilon_{t-1}^-$, em que $\epsilon_{t-1}^+ = \epsilon_{t-1}$ se $\epsilon_{t-1} > 0$ e $\epsilon_{t-1}^+ = 0$ se $\epsilon_{t-1} \leq 0$. Igualmente temos que $\epsilon_{t-1}^- = \epsilon_{t-1}$ se $\epsilon_{t-1} \leq 0$ e $\epsilon_{t-1}^- = 0$ se $\epsilon_{t-1} > 0$.

serem comparáveis com o GARCH(1,1) encontrado como o melhor modelo dado o critério assumido.

Portanto, antes de realizarmos as previsões de cada uma das modelagens da família GARCH, fizemos uma divisão da nossa base de dados entre períodos de treino e teste com razão de 80/20. Tal divisão tem como finalidade garantir que os modelos propostos sejam testados fora de uma amostra escolhida, de modo que seu poder preditivo seja posto em prática em situações que eles ainda não tinham visto e performado, analisando qual deles têm melhores resultados na previsão da volatidade do S&P 500.

5 Resultados

Sabendo agora um pouco dos modelos propostos e estimados para a nossa série do S&P 500, somos então capazes de comparar a capacidade preditiva para a presente série de volatilidade do S&P 500.

Antes disso, vale ressaltar algumas características comparativas já de possível análise, olhando apenas para os critérios de informação (em especial o de Akaike e o Bayesiano) somos capazes de posicionar uma análise relativa a melhor log verossimilhança, ou seja pensar na maximização da probabilidade dos dados observados, penalizando pelo número de parâmetros, de tal forma a buscar minimizar o critério de informação. Assim, tanto pelo critério AIC quanto pelo BIC temos que o melhor modelo é o t-Garch, como indicado pela Tabela 3

Tabela 3 – Critérios de Informação:

Modelo	AIC	BIC
GARCH	5029.29	5051.56
GJR-GARCH	4991.88	5019.71
EGARCH	5041.79	5064.05
t-GARCH	4915.04	4942.87

Fonte: Próprio Autor.

Partindo disso olhamos agora para a predição dos modelos, vale reforçar como indicado no Capítulo 4 que 20% da base de dados foi deixada de fora do treino dos modelos, de tal forma a usar essa parte da base agora para comparar a predição com o observado na realidade. Dessa forma, construímos a predição de todos os modelos e comparamos com a volatilidade realizada do período, como indicado na Figura 5.

Seguindo então as trajetórias preditivas estimadas pelos modelos traçamos alguns critérios, olhamos para o MAE (Erro absoluto médio), MSE (Erro quadrático médio) e RMSE (Raiz do erro quadrático médio), sobre quais tais métricas permitem olhar para a diferença do valor realizado de volatilidade e a série de predição para cada modelo, com diferenças relativas ao módulo da diferença, quadrado da diferença e raiz da diferença quadrática respectivamente. Dessa forma, apresentamos na Tabela 4 as presentes métricas, além de introduzir a função de log verossimilhança como uma outra função comparativa extra.

Dessa forma, o melhor critério preditivo relativo aos erros estão atrelados a sua minimização, enquanto para a log verossimilhança olhamos para a maximização. Assim

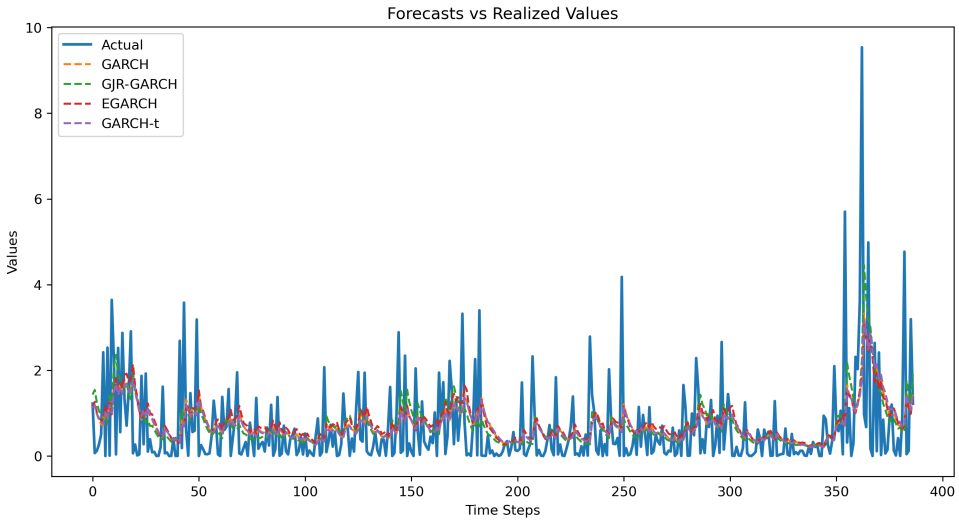

Figura 5 – Predição de volatilidade dos modelos comparativo à realidade do período.

Fonte: Próprio Autor.

Tabela 4 – Métricas de erro e função de log verossimilhança:

Modelo	MAE	MSE	RMSE	Log-Likelihood
GARCH	0.690257	0.997135	0.998567	-456.376784
GJR-GARCH	0.675588	0.995770	0.997883	-452.029388
EGARCH	0.711771	1.007337	1.003662	-457.822786
t-GARCH	0.682758	0.989000	0.994485	-456.013745

Fonte: Próprio Autor.

para o MAE o melhor modelo é o GJR-GARCH, todavia quando olhamos para o MSE, RMSE e verosimilhança temos como melhor modelo indicativo o t-GARCH. Ainda assim, notamos que a diferença entre os erros dos modelos presentes são extremamente pequenas e podem ser um possível indicador que a diferença entre os erros não seja estatisticamente significantes, para aprofundar essa ideia partimos para o teste Diebold-Mariano.

O teste Diebold-Mariano (DM teste) compara a diferença dos erros preditivos entre 2 modelos, sobre o qual construímos uma estatística DM (que segue uma distribuição t-student) considerativa dessa diferença, temos então H_0 relativo a diferença entre os erros ser igual a zero, ou seja apresentam capacidade preditiva similar, enquanto H_1 indica diferença entre e os erros, ou seja existe diferença na capacidade preditiva entre os modelos. Dessa forma, apresentamos os resultados na Tabela 5.

Assim, o interessante de analisar é que não rejeitamos H_0 a 5% de significância para a comparação entre os modelos GJR-GARCH e GARCH, além dos modelos t-GARCH e GJR-GARCH. Dessa forma, não somos capazes de afirmar quando comparada a capacidade preditiva entre os modelos GJR-GARCH com GARCH e t-GARCH com GJR-GARCH existe algum melhor entre cada dupla, quando pensando nos erros de predição.

Logo, podemos afirmar que o pior modelo entre os presente em sua capacidade preditiva de volatilidade é o EGARCH, seguindo pelo modelo GARCH padrão quando olhado para as métricas da Tabela 4, mesmo que a diferença dos erros entre o GARCH e o GJR-GARCH não seja estatisticamente significante, assim como a diferença dos erros

Tabela 5 – Resultados do Teste DM (Diebold-Mariano):

Modelos Comparados	Estatística DM	P-valor	Interpretação para 5%
GARCH vs GJR-GARCH	-0.0082	0.9761	Não significativo
GARCH vs EGARCH	13.8207	0.0000	Significativo
GARCH vs t-GARCH	-6.3446	2.19×10^{-10}	Significativo
GJR-GARCH vs EGARCH	5.3477	8.75×10^{-8}	Significativo
GJR-GARCH vs t-GARCH	-1.3369	0.1781	Não significativo
EGARCH vs t-GARCH	-14.6857	0.0000	Significativo

Fonte: Próprio Autor.

entre o modelo GJR-GARCH e o t-GARCH. Ainda assim, somos capazes de afirmar que o modelo t-GARCH tem melhor capacidade preditiva comparativa ao GARCH padrão devido aos resultados das Tabelas 4 e 5.

Em suma, os nosso resultados se provam muito interessantes no universo acadêmico, fomos capazes de agregar ao debate presente com os nosso achados, ao levantar algumas considerações adicionais de importantes considerações partindo para frente. Primeiramente, como foi demonstrado pelos resultados foco em assimétrica sobre o quesito de distribuição não é tão evidente como é afirmado por (AWARTANI; CORRADI, 2005) e (LIU; HUNG, 2010), já que notamos que modelos que focam em quesitos de assimetria como EGARCH e GJR-GARCH não necessariamente apresentam resultados de predição melhor que modelos como t-GARCH, sendo ainda inconclusivo pois notamos que a diferença entre GJR-GARCH e t-GARCH não é estatisticamente significante. Não só isso, também encontramos resultados contraditorios aos achados de (LIU; HUNG, 2010) que enfatizam que quando não modelamos assimetria o modelo GARCH(1,1) tem a melhor capacidade preditiva, ao notar que o nosso modelo t-GARCH apresenta melhor capacidade preditiva comparativa ao modelo GARCH(1,1).

6 Conclusões

Este estudo comprometeu-se a expor uma análise econométrica acerca da previsão de volatilidade do índice S&P 500 a partir de um embate entre modelos da família GARCH. Para isso, utilizamos dados em time-series entre 2017 a 2024 do Finance (2024) do S&P 500, índice formado pelas 500 principais ações listadas nas bolsas NYSE e NASDAQ pelo seu *market share* e liquidez.

Uma vez que realizamos a análise exploratória de nossos dados, identificando a presença de heterocedassticidade pelo teste de White na seção 3, definimos a necessidade de modelar a variância dos retornos do índice, sua volatilidade, a fim de prevê-la corretamente. Assim, seguindo as críticas de (STARICA, 2003), (LIU; HUNG, 2010) e (AWARTANI; CORRADI, 2005) ao modelo original GARCH(p,q) de (BOLLERSLEV, 1986), nós decidimos propor uma avaliação em conjunta entre os modelos GARCH(p,q), EGARCH(p,q), GJR-GARCH(p,q) e t-GARCH(p,q) para decidir tem o maior poder preditivo com base no teste Diebol-Mariano (DM teste), que compara a diferença entre os erros preditivos dos modelos, 2 a 2. Vale notar que durante a otimização da ordem (p,q) de *lags* do modelo GARCH(p,q) via critério de informação AIC, escolhemos a ordem (1,1) como melhor, e por isso o embate entre a família GARCH será com ordem padronizada em (1,1).

Assim, separamos nossa base de dados em períodos de treino e teste numa razão de 80/20, de modo que cada modelo pudesse aprender com os dados com os quais seriam alimentados, e preverem a variância do S&P 500, pondo-os à prova e comparando suas previsões com os valores reais do índice estabelecido. Realizando o teste DM, segundo as hipóteses nula e alternativa especificadas na seção 5, a tabela 5 revela que a diferença dos erros preditivos dos outros modelos propostos em comparação ao t-GARCH(1,1) são todos significativos a 5% de significância com exceção para comparação ao GJR-GARCH, além de encontramos também na tabela 5 não significância na comparação entre o GJR-GARCH e o GARCH padrão. Portanto, não conseguimos afirmar sobre qual é de fato o melhor modelo preditivo com o resultado presente, apenas fomos capazes de apresentar algumas outras novas visões, indicativas que não se deve desconsiderar totalmente modelagem da distribuição dos erros, ao encontrar um impasse entre os modelos t-GARCH e GJR-GARCH pelo teste Diebold-Mariano, dessa forma apenas podemos analisar esses modelos como similares em capacidade preditiva.

Referências

AWARTANI, B. M. *et al.* Predicting the volatility of the sp-500 stock index via garch models: the role of asymmetries. **International Journal of Forecasting**, v. 21, n. 1, p. 167–183, 2005.

BLACK, F. *et al.* The pricing of options and corporate liabilities. **Journal of political economy**, The University of Chicago Press, v. 81, n. 3, p. 637–654, 1973.

BOLLERSLEV, T. Generalized autoregressive conditional heteroskedasticity. **Journal of econometrics**, Elsevier, v. 31, n. 3, p. 307–327, 1986.

ENGLE, R. F. Autoregressive conditional heteroscedasticity with estimates of the variance of united kingdom inflation. **Econometrica: Journal of the econometric society**, JSTOR, p. 987–1007, 1982.

FINANCE, Y. **Pontuação do índice SP 500**. 2024. Https://finance.yahoo.com/quote/

LIU, H.-C. *et al.* Forecasting sp-100 stock index volatility: The role of volatility asymmetry and distributional assumption in garch models. **Expert Systems with Applications**, v. 37, n. 7, p. 4928–4934, 2010.

MARTENS, M. *et al.* **Modeling and forecasting S&P 500 volatility: Long memory, structural breaks and nonlinearity**. [S.l.], 2004.

SRINIVASAN, P. Modeling and forecasting the stock market volatility of s&p 500 index using garch models. **IUP Journal of Behavioral Finance**, IUP Publications, v. 8, n. 1, p. 51, 2011.

STARICA, C. Is garch (1, 1) as good a model as the nobel prize accolades would imply. **Preprint**, 2003.